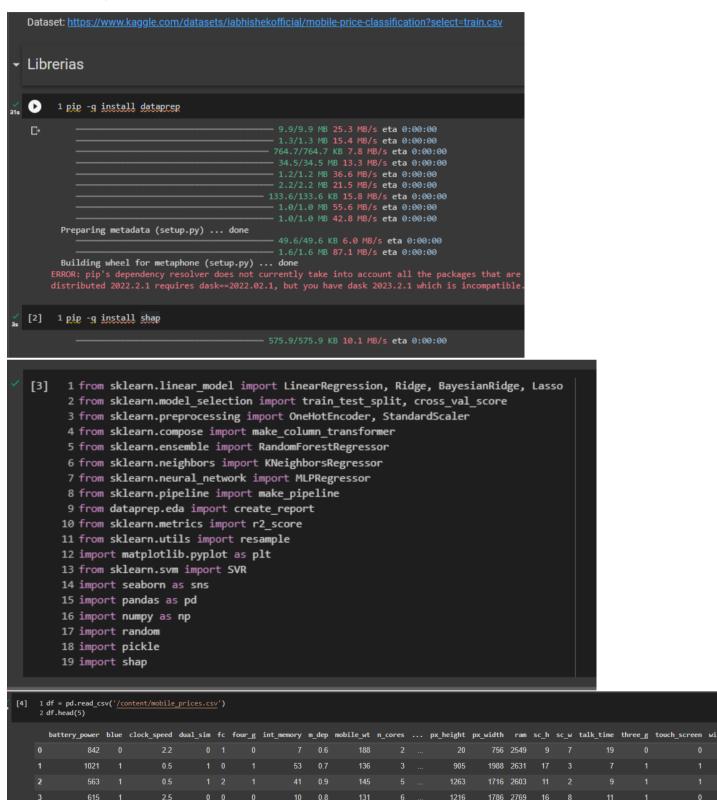
Documento de infraestructura

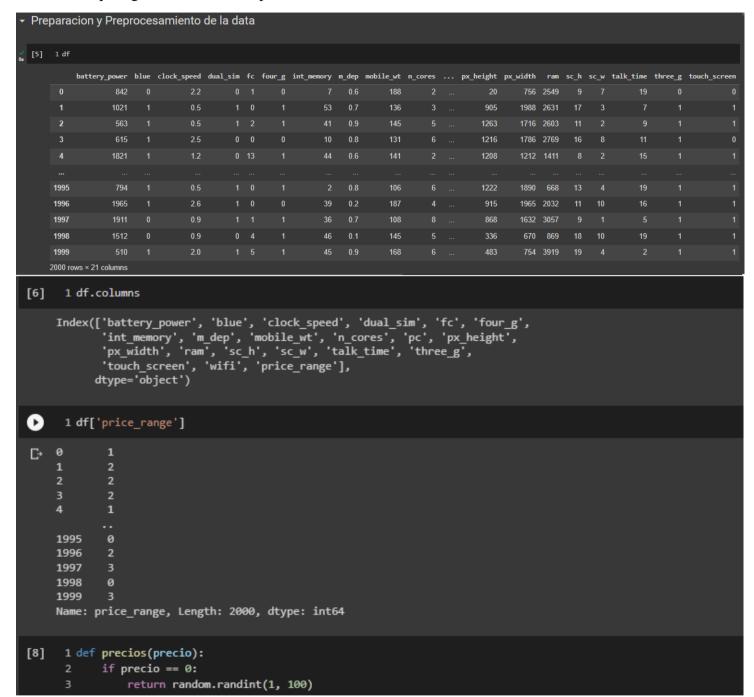
Addison Amin Reyes Cedano, 2021-2026

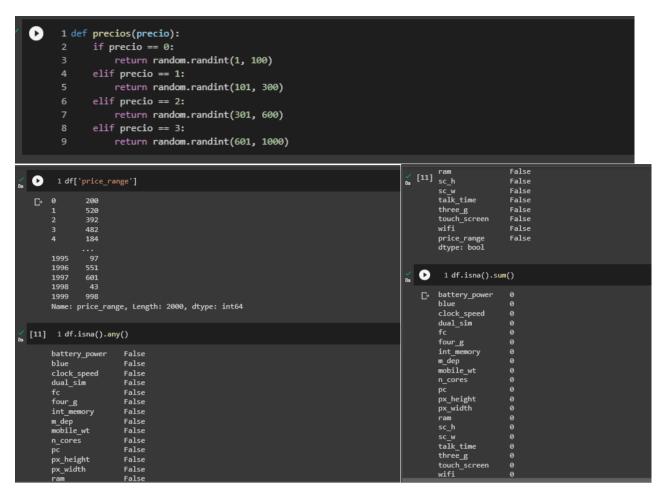
La idea de mi <u>proyecto</u> es la siguiente, dado un dataframe de caracteristicas acerca de celulares predecir su precio gracia a modelos de regresion de sklearn. Lo primero fue elegir el dataframe que es <u>este</u>, aquí el codigo de las librerias y abriendo el dataframe en colab.



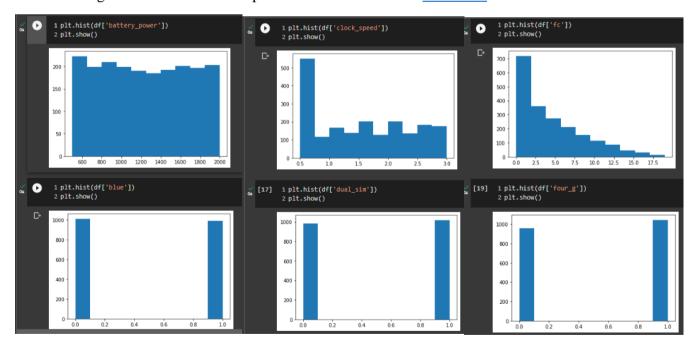
5 rows × 21 columns

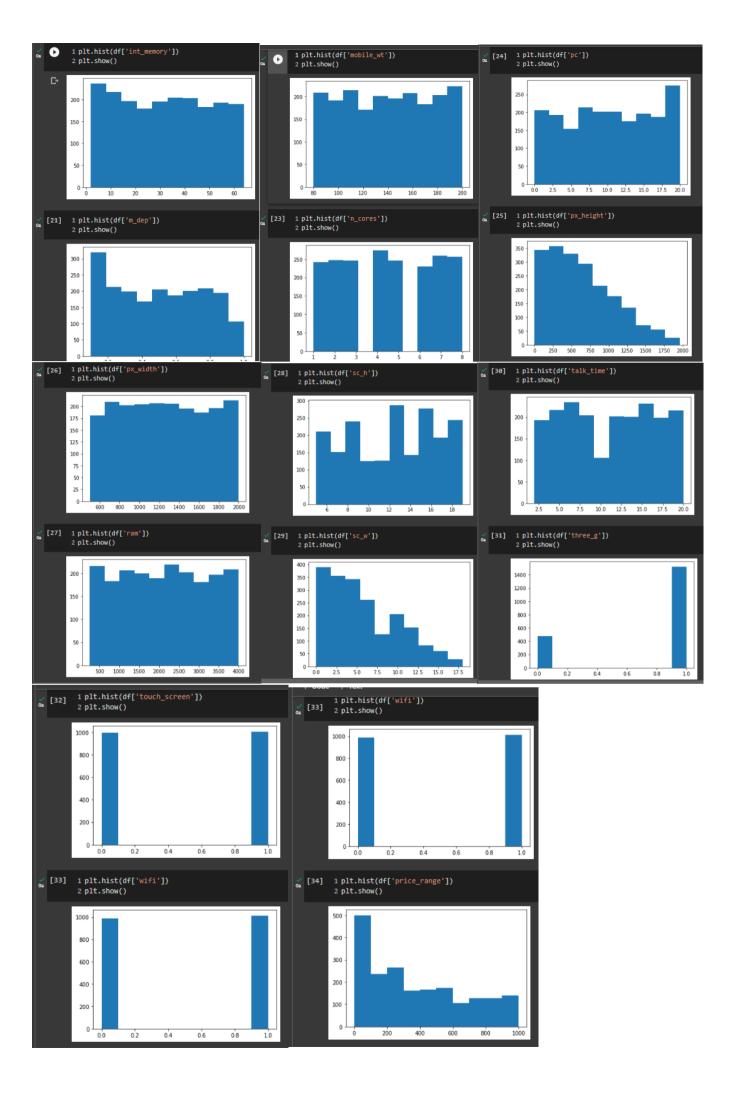
Luego de la recolección de datos inicia el proceso de preparación y preprocesamieno de la data, lo primero que hice fue analizar el dataframe y ver cada columna, me fije que la columna de precio de rango tenia un formato de 0 a 3, pero decidi cambiar la columna a un formato de dolares desde 0 a 1000 con una función de precios aplicandolo al dataframe con la función apply y por ultimo revisando si hay valores nulos dentro del dataframe, aquí algunas fotos de lo explicado.





Una vez hecha la preparacion inice el proceso de analisis descriptivo (EDA), cree un <u>reporte</u> con dataprep e hice un histograma de cada columna para analizar los datos del <u>dataframe</u>.





Una vez analizado los datos empece el entrenamiento de los modelos de regresion, primero cree los valores para el entrenamiento dividiendo el sataframe en X con todas las etiquetas de entrada para el modelo que serian las caracteristicas del celular y Y la etiqueta de salida que seria el precio de salida. Una vez teniendo los valores X Y dividi las columnas numericas y las columnas categoricas para pasarlo por la funcion make_column_transformer, luego cree los valores de entrenamiento y testeo para pasarselos a los modelos requeridos. Aquí fotos del entrenamiento:

```
Entrenamiento del modelo
  [35] 1 x = df.iloc[:, :-1]
         2 y = df.iloc[:, -1]
  [36] 1 numerical_columns = x.columns[(x.dtypes == "float64") | (x.dtypes == "int64")]
         2 categorical_columns = x.columns[(x.dtypes == "object")]
  [37] 1 col_transf = make_column_transformer(
               (OneHotEncoder(handle_unknown='ignore'), categorical_columns),
              (StandardScaler(), numerical_columns),
              remainder="passthrough")
  [38] 1 X_train, X_test, y_train, y_test = train_test_split(x, y, random_state=2, test_size=0.2)
  [39] 1 models = []
         2 models.append(("LR", LinearRegression()))
         3 models.append(("RR", Ridge()))
        4 models.append(("BR", BayesianRidge()))
5 models.append(("LASSO", Lasso()))
6 models.append(("KNN", KNeighborsRegressor()))
         7 models.append(("RF", RandomForestRegressor()))
         8 models.append(("SVR", SVR()))
         9 models.append(("NNMLP", MLPRegressor()))
  [40] 1 pipelines = {name: make_pipeline(col_transf, model) for name, model in models}
  [40] 1 pipelines = {name: make_pipeline(col_trans+, model) for name, model in models}
         1 results = []
         2 scoring = 'r2'
         3 kfolds = 5
         5 for name, pipeline in pipelines.items():
         6 cv_results = cross_val_score(pipeline, X_train, y_train, cv=kfolds, scoring=scoring)
         7 results.append({name: cv_results})
   Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.
        Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.
        Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.
        Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.
        Stochastic Optimizer: Maximum iterations (200) reached and the optimization hasn't converged yet.
(42) 1 results
        [{'LR': array([0.81293774, 0.81462397, 0.81412339, 0.81801702, 0.82682383])},
         {'RR': array([0.81296164, 0.81464875, 0.81416408, 0.81794783, 0.82682736])}, {'BR': array([0.81303408, 0.8147228, 0.81429489, 0.8176988, 0.82683142])}, {'LASSO': array([0.81310064, 0.8153513, 0.81764911, 0.81926212, 0.82784204])},
         {'KNN': array([0.49614521, 0.54294129, 0.54601597, 0.5518055 , 0.51683191])},
         {'RF': array([0.85410933, 0.84227362, 0.84676293, 0.85895864, 0.84665268])},
         [43] 1 best_model = sorted(results, key=lambda x: list(x.values())[0].mean(), reverse=True)[0]
         2 best_pipeline = pipelines[list(best_model.keys())[0]]
[44] 1 best_model
        {'RF': array([0.85410933, 0.84227362, 0.84676293, 0.85895864, 0.84665268])}
```

```
{'KNN': array([0.49614521, 0.54294129, 0.54601597, 0.5518055 , 0.51683191])},
      {'NNMLP': array([0.66257225, 0.68568835, 0.66515614, 0.61789922, 0.68766671])}]
[43] 1 best_model = sorted(results, key=lambda x: list(x.values())[0].mean(), reverse=True)[0]
      2 best pipeline = pipelines[list(best model.keys())[0]]
[44]
     1 best_model
     {'RF': array([0.85410933, 0.84227362, 0.84676293, 0.85895864, 0.84665268])}
 0
      1 fig = plt.figure()
      2 ax = fig.add_subplot(111)
      3 plt.boxplot([list(dict_.values())[0] for dict_ in results])
      4 ax.set_xticklabels([list(dict_.keys())[0] for dict_ in results])
      5 plt.show()
      0.8
      0.6
      0.4
      0.2
      0.0
                                          0
          LR
               RR
                        LASSO KNN
                                    RE
                                         SVR
                                             NNMLP
0
    1 best pipeline.fit(X train, y train)
                                                            0
     2 best_pipeline.predict(X_test)
r, array([ 57.22, 502.16, 140.48, 510.35, 814.66, 220.13, 843.33, 799.93,
```

```
1 best_pipeline.fit(X_train, Y_train)
2 best_pipeline.predict(X_test)

P. array([ 57.22, 502.16, 140.48, 510.35, 814.66, 220.13, 843.33, 799.93, 284.14, 281.16, 227.37, 49.69, 486.13, 793.47, 116.67, 803.84, 486.22, 127.78, 186.73, 811.14, 71.66, 664.67, 580.84, 486.22, 127.78, 186.73, 811.14, 71.66, 664.67, 580.84, 486.22, 127.78, 186.73, 181.14, 71.66, 664.67, 580.84, 486.22, 127.78, 186.73, 181.14, 71.66, 664.67, 580.84, 486.22, 127.78, 186.83, 186.83, 188.23, 88.2, 88.2, 88.27, 61.39, 495.22, 159.22, 256.69, 186.22, 180.62, 180.63, 180.63, 664.67, 580.64, 411.81, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23, 186.23,
```

El mejor modelo fue el de random forest use la metrica de r2 score para seleccionar el meor modelo, luego con la librería de pickle exporte el modelo para poder usarlo en una aplicación externa a la que se le pasaran los valores de entrada y dependiendo de las caracteristicas dara el precio del celular, aquí algunas fotos de la api.

```
1 filename = 'mobile_prices.pkl'
           2 pickle.dump(best_pipeline, open(filename, 'wb'))
[ ] 1 import pandas as pd
          2 import sklearn
          3 import pickle
          5 if __name__ == '__main__':
          6 mp_mod = pickle.load(open('mobile_prices.pkl', mode = 'rb'))
          8 print("Bienvenid@! Digita los datos del celular.")
         10 battery_power = input("\nBateria total que el celular puede almacenar en miliamperios(mAH): ")
                talk_time = input("Tiempo que dura la bateria sin cargar: ")
                int_memory = input("Gigabytes de la memoria interna:
                clock_speed = input("Velocidad del microprocesador:
         14 n_cores = input("Numero de nucleos del procesador: ")
         15  ram = input("Ram del telefono en megabytes: ")
         16 dual_sim = input("Tiene dual sim (1: si, 0: no): ")
         17 blue = input("Tiene bluetooth (1: si, 0: no): ")
         18 wifi = input("Puede usar wifi (1: si, 0: no): ")
         19 three_g = input("Puede utilizar 3G (1: si, 0: no): ")
         20 four_g = input("Puede utilizar 4G (1: si, 0: no): ")
         21 touch_screen = input("El celular es touch (1: si, 0: no):")
         22 pc = input("Megapixeles de la camara principal: ")
         23 fc = input("Megapixeles de la camara frontal: ")
         24 px_height = input("Resolucion de la altura en pixeles: ")
         25 px_width = input("Resolucion del ancho en pixeles: ")
         26 sc_h = input("Altura del telefono en cm: ")
         27 sc_w = input("Anchura del telefono en cm: ")
         28 m_dep = input("Profundidad del celular en cm: ")
         29 mobile wt - input("Peso del celular: ")
    int_memory = input("Gigabytes de la memoria interna: ")

clock_speed = input("Welocidad del microprocesador: ")

n_cores = input("Mumero de nucleos del procesador: ")

n_minut("Sam del telefono en megabytes: ")

dual_sim = input("Tiene dual sim (1: si, 0: no): ")

blue = input("Tiene bluetooth (1: si, 0: no): ")

wifi = input("Puede usar wifi (1: si, 0: no): ")

three_g = input("Puede utilizar 36 (1: si, 0: no): ")

touch_screen = input("El celular es touch (1: si, 0: no): ")

touch_screen = input("El celular es touch (1: si, 0: no): ")

pc = input("Megapixeles de la camara principal: ")

pc = input("Megapixeles de la camara frontal: ")

px_height = input("Resolucion de la altura en pixeles: ")

px_with = input("Resolucion del ancho en pixeles: ")

sc_m = input("Altura del telefono en cm: ")

m_dep = input("Profundidad del celular en cm: ")
     11 celular = pd.DataFrame([battery_power, blue, clock_speed, dual_sim, fc, four_g, int_memory, m_dep, mobile_wt, n_cores, pc, px_height, px_width, ram, sc_h, sc_w, talk_time, three_g, touch_scree 22 celular = celular.transpose().rename(columns={0: 'battery_power', 1: 'blue', 2: 'clock_speed', 3: 'dual_sim', 4: 'fc', 5: 'four_g', 6: 'int_memory', 7: 'm_dep', 8: 'mobile_wt', 9: 'n_cores', 1
     34 prediccion = mp_mod.predict(celular)
 C. Bienvenid@! Digita los datos del celular.
     Bateria total que el celular puede almacenar en miliamperios(mAH): 2000
Tiempo que dura la bateria sin cargar: 20
Gigabytes de la memoria interna: 6
Velocidad del microprocesador: 0.9
Numero de nucleos del procesador: 6
Ram del telefono en megabytes: 6000
Tieme dual cim (f. : in 20.00):
      Tiene dual sim (1: si, 0: no): 1
Tiene bluetooth (1: si, 0: no): 1
```

Por ultimo use la librería SHAP para ver que caracteristicas influian mas en el modelo y vistos los graficos se nota como la RAM es lo que influye mas en el modelo que cualquier otra caracteristicas.

